

Validação Empírica do Motor Preditivo

Nota de edição. A numeração adotada (Capítulo 5 e seções 5.1 a 5.11) é provisória e deve ser ajustada conforme a posição final deste capítulo na monografia. As figuras referenciadas estão em `ml-service/analysis/figures/` e todas as tabelas foram geradas pela execução do código de produção do serviço, com semente fixa — não há valor transcrito manualmente. O detalhamento matemático dos modelos, referido ao longo do texto, encontra-se no relatório técnico `relatorio-modelos-preditivos.pdf`.

5.1 Objetivo e escopo da validação

Este capítulo apresenta a validação empírica do motor preditivo do StockSense. O objetivo é verificar, de forma reproduzível e auditável, três propriedades do componente responsável pela previsão de demanda: (a) que ele recupera corretamente a estrutura presente em uma série histórica de vendas; (b) que o erro de previsão resultante é mensurável, estável entre diferentes janelas de avaliação e comparável entre produtos de escalas distintas; e (c) que a previsão obtida se converte em parâmetros de reposição coerentes com a situação de estoque de cada item.

Delimita-se desde já o que não está no escopo. A validação aqui conduzida utiliza um conjunto de dados sintético, gerado com estrutura conhecida e semente fixa. Não se trata, portanto, de uma medição do desempenho do sistema sobre a demanda real de um estabelecimento — essa verificação externa é registrada como trabalho futuro. A distinção é relevante e convém explicitá-la antes de qualquer resultado: o experimento descrito adiante tem a natureza de uma **validação de instrumentação**, isto é, destina-se a demonstrar que o instrumento de medida funciona corretamente, e não a medir o mundo.

Sobre o uso de dados sintéticos e o risco de circularidade

Uma objeção previsível ao uso de dados gerados artificialmente é a de que o experimento seria circular: se a estrutura dos dados foi definida por quem conduz o teste, encontrá-la não provaria nada. A objeção é pertinente e a resposta a ela orienta a leitura de todo o capítulo.

Justamente porque a estrutura verdadeira é conhecida por construção, torna-se possível verificar se o motor a recupera — o que seria impossível com dados reais, cuja estrutura verdadeira ninguém conhece. O que se testa aqui não é a capacidade preditiva em campo, mas a correção da implementação: se o instrumento, submetido a um sinal conhecido, devolve a medida esperada. A Seção 5.8 apresenta o resultado que melhor ilustra esse papel, ao mostrar que o otimizador identificou não apenas a estrutura da série, mas também o fato de que ela é estacionária.

5.2 Protocolo experimental

5.2.1 Conjunto de dados

Foram gerados **10 produtos com 365 dias** de histórico diário de vendas, mediante semente fixa (SEED = 42), representando perfis de demanda contrastantes encontrados em um mercado de bairro. A quantidade vendida de cada produto em cada dia resulta da composição multiplicativa de quatro fatores:

```
quantidade(t) = round( demanda_base × tendência(t) × fator_semanal(t) × ruído(t) )
```

A **demanda base** é constante por produto e varia de 5 unidades diárias (sal refinado) a 30 (pão francês). A **tendência** é um crescimento linear de 20% ao longo do período. O **fator semanal** é um multiplicador fixo por dia da semana, que atinge 1,45 aos sábados e cai a 0,30 aos domingos — uma amplitude de quase cinco vezes entre o melhor e o pior dia, característica do varejo de bairro e razão pela qual se adotou ciclo sazonal de sete dias nos dois modelos. O **ruído** é gaussiano multiplicativo centrado na unidade, cujo desvio padrão é o parâmetro que diferencia os perfis de produto.

Sobrepõem-se ainda os fechamentos do estabelecimento: domingos têm 40% de probabilidade de registrar venda nula e os doze feriados nacionais do período, 60%. Esse mecanismo reproduz o comportamento operacional de um mercado de bairro e constitui a principal fonte de dificuldade para os modelos, uma vez que introduz descontinuidades não previsíveis a partir do calendário semanal.

5.2.2 Divisão temporal dos dados

A avaliação emprega divisão cronológica na proporção de **80% para treino e 20% para teste**, o que resulta em 292 dias de treino (2024-01-01 a 2024-10-18) e 73 dias de teste (2024-10-19 a 2024-12-30). A divisão é feita por posição no índice temporal, preservando integralmente a ordem cronológica das observações.

Por que a divisão não pode ser aleatória

Em problemas de aprendizado supervisionado convencional é prática corrente embaralhar as observações antes de separar treino e teste, de modo a evitar vieses de ordenação. Em séries temporais esse procedimento é inválido. Embaralhar colocaria dias posteriores no conjunto de treino e dias anteriores no conjunto de teste, de forma que o modelo utilizaria informação do futuro para prever o passado. O erro medido resultaria artificialmente baixo e desprovido de significado, pois não corresponderia à situação de uso — na qual apenas o passado está disponível. Por essa razão, a implementação do serviço proíbe explicitamente o uso de rotinas de divisão aleatória, e a separação é feita por posição cronológica (HYNDMAN; ATHANASOPOULOS, 2021).

5.2.3 Métricas de avaliação

Adotaram-se três métricas de erro, calculadas sobre a janela de teste:

```
MAE = média( |real - previsto| )
RMSE = raiz( média( (real - previsto)² ) )
MAPE = média( |real - previsto| / real ) × 100
```

Métrica	Unidade	Papel na avaliação
MAE	unidades do produto	erro médio típico; é a métrica de leitura mais direta para o gestor do estabelecimento
RMSE	unidades do produto	por elevar o desvio ao quadrado, penaliza desproporcionalmente os erros grandes; identifica falhas pontuais severas
MAPE	percentual	adimensional, permite comparar produtos de volumes distintos; é o critério de seleção do modelo

A seleção do modelo vencedor utiliza o **MAPE**. A escolha decorre de uma exigência do sistema: a decisão precisa ser comparável entre produtos de escalas muito diferentes. Um erro absoluto de três unidades é excelente para o pão francês, cuja demanda média supera trinta unidades diárias, e inaceitável para o sal refinado, cuja demanda é de cinco. Somente uma métrica percentual permite afirmar que um produto é mais previsível que outro e alimentar o indicador de acurácia exibido no painel, definido como 100 menos o MAPE do modelo selecionado.

Registra-se um aspecto do cálculo que afeta a interpretação comparativa das três métricas. Como o MAPE divide pelo valor observado, os dias de venda nula — decorrentes dos fechamentos descritos na seção anterior — produziriam divisão por zero. A implementação calcula o MAPE **apenas sobre as observações de valor real positivo**, enquanto RMSE e MAE consideram todos os dias da janela. As três métricas, portanto, não incidem exatamente sobre o mesmo conjunto de pontos, o que deve ser levado em conta ao confrontá-las.

5.2.4 Equivalência com o sistema em produção

A camada de análise que produziu os resultados deste capítulo **importa os módulos de produção do serviço** — os mesmos que o endpoint de previsão executa — em vez de reimplementar as fórmulas em ambiente experimental. A decisão tem consequência direta sobre a validade interna do estudo: não existe uma segunda implementação capaz de divergir da primeira, e os valores apresentados adiante são, por construção, os mesmos que o sistema produz em operação. Trata-se de eliminar uma fonte clássica de discrepância entre o resultado relatado em trabalhos acadêmicos e o comportamento do artefato efetivamente entregue.

5.3 Caracterização do conjunto de dados

A Tabela 5.1 apresenta a estatística descritiva das dez séries geradas. A coluna *variabilidade* corresponde ao parâmetro de ruído utilizado na geração, enquanto o coeficiente de variação (CV) é medido sobre a série resultante.

id	Produto	Variab.	Média/dia	σ	CV	% zeros
1	Arroz 5kg	0,15	12,40	5,46	0,47	6,0%
2	Feijão Carioca 1kg	0,15	8,27	3,86	0,51	8,5%
3	Leite Integral 1L	0,35	21,52	11,62	0,58	7,7%
4	Pão Francês	0,40	30,58	18,24	0,64	6,8%
5	Banana Prata kg	0,45	16,53	10,57	0,68	6,3%
6	Sal Refinado 1kg	0,05	5,21	2,29	0,48	7,7%
7	Açúcar Cristal 1kg	0,05	7,27	3,21	0,48	7,4%
8	Óleo de Soja 900ml	0,20	6,09	2,89	0,51	6,8%
9	Frango Inteiro kg	0,30	10,44	5,45	0,56	7,4%
10	Refrigerante 2L	0,25	14,49	7,11	0,53	6,8%

Tabela 5.1 — Estatística descritiva dos dez produtos sintéticos.

O conjunto cobre uma faixa ampla de comportamentos. Nos extremos situam-se o sal refinado e o açúcar cristal, com variabilidade de 0,05 e demanda praticamente determinística, e a banana prata, com variabilidade de 0,45 e oscilação diária acentuada. Essa amplitude é intencional: permite observar como o desempenho preditivo se degrada à medida que a componente aleatória cresce, em vez de avaliar o motor em um único regime favorável.

Uma observação menos evidente merece registro, pois condiciona a leitura dos resultados. O coeficiente de variação não assume valores baixos nem mesmo para os produtos de ruído mínimo — o sal refinado, com variabilidade de 0,05, apresenta CV de 0,48. A razão é que o CV mede toda a dispersão da série, e a própria oscilação semanal, ao alternar entre 1,45 aos sábados e 0,30 aos domingos, já produz dispersão considerável. Conclui-se que **parte substancial do desvio observado em cada produto é estrutura previsível, não ruído** — e é precisamente essa parcela que os modelos são capazes de capturar. A distinção explica por que produtos com desvio padrão semelhante podem apresentar erros de previsão muito diferentes.

5.4 Análise exploratória: existe sinal previsível?

Antes de ajustar qualquer modelo, cabe verificar se as séries contêm estrutura passível de ser aprendida. Aplicou-se a decomposição aditiva com período de sete dias, que separa a série observada em três componentes: tendência, sazonalidade e resíduo. O critério de leitura é direto — se a componente sazonal apresenta amplitude nítida e regular e o resíduo é pequeno em relação ao sinal, existe estrutura a ser modelada, o que justifica o emprego de modelos de série temporal em lugar de uma simples média histórica.




Figura 5.1 — Decomposição da série do Arroz 5kg (id 1). A sazonalidade semanal aparece como oscilação regular de amplitude constante, e a tendência de crescimento é claramente separável do resíduo.



Figura 5.2 — Decomposição da série da Banana Prata kg (id 5). A estrutura sazonal é a mesma, porém o resíduo apresenta amplitude muito superior, refletindo a variabilidade intrínseca do produto.

O contraste entre as duas figuras antecipa e explica os resultados das seções seguintes. Ambos os produtos possuem estrutura sazonal semanal igualmente bem definida — e, portanto, igualmente aprendível. O que os distingue é a magnitude do resíduo, isto é, da parcela que nenhum modelo pode prever. Trata-se de um limite imposto pelo dado, não pelo método, e é

sobre esse pano de fundo que os erros relatados adiante devem ser interpretados.

5.5 Resultados comparativos

5.5.1 Métricas por produto e modelo

Os dois modelos foram treinados e avaliados em todos os dez produtos, segundo o protocolo da Seção 5.2. A Tabela 5.2 consolida os resultados; as linhas destacadas indicam o modelo selecionado pelo critério de menor MAPE.

id	Produto	Modelo	MAPE (%)	RMSE	MAE	Selec.
1	Arroz 5kg	holt_winters	12,4887	2,2522	1,7583	
1	Arroz 5kg	prophet	12,4606	2,2451	1,7488	✓
2	Feijão Carioca 1kg	holt_winters	13,2639	1,4155	1,1231	✓
2	Feijão Carioca 1kg	prophet	13,3540	1,4191	1,1279	
3	Leite Integral 1L	holt_winters	42,0977	9,1086	7,4113	✓
3	Leite Integral 1L	prophet	42,7739	9,1659	7,4487	
4	Pão Francês	holt_winters	81,2510	16,0704	11,9428	✓
4	Pão Francês	prophet	84,1720	16,2863	12,1403	
5	Banana Prata kg	holt_winters	66,6753	8,0727	6,1818	
5	Banana Prata kg	prophet	66,6271	8,0730	6,1818	✓
6	Sal Refinado 1kg	holt_winters	9,6252	1,0853	0,5875	
6	Sal Refinado 1kg	prophet	9,5655	1,0844	0,5851	✓
7	Açúcar Cristal 1kg	holt_winters	8,8945	1,7412	0,9415	✓
7	Açúcar Cristal 1kg	prophet	9,0065	1,7404	0,9452	
8	Óleo de Soja 900ml	holt_winters	21,4335	2,1356	1,4210	✓
8	Óleo de Soja 900ml	prophet	21,4615	2,1373	1,4216	
9	Frango Inteiro kg	holt_winters	25,3962	3,7548	2,6511	
9	Frango Inteiro kg	prophet	25,2870	3,7482	2,6434	✓
10	Refrigerante 2L	holt_winters	28,2987	4,7083	3,3909	✓
10	Refrigerante 2L	prophet	28,3084	4,7087	3,3912	

Tabela 5.2 — MAPE, RMSE e MAE por produto e modelo na janela de teste.

O placar agregado indica **6 seleções do Holt-Winters e 4 do Prophet**. Esse número, contudo, é insuficiente para sustentar qualquer conclusão sobre superioridade de um método, pois não informa a magnitude das diferenças. A Tabela 5.3 apresenta as margens.

Produto	Margem de MAPE (pontos percentuais)
10 — Refrigerante 2L	0,0097
8 — Óleo de Soja 900ml	0,0280
1 — Arroz 5kg	0,0281
5 — Banana Prata kg	0,0482
6 — Sal Refinado 1kg	0,0597
2 — Feijão Carioca 1kg	0,0901
9 — Frango Inteiro kg	0,1092
7 — Açúcar Cristal 1kg	0,1120

Produto	Margem de MAPE (pontos percentuais)
3 — Leite Integral 1L	0,6762
4 — Pão Francês	2,9210

Tabela 5.3 — Diferença absoluta de MAPE entre os dois modelos, por produto.

Leitura dos resultados

Em **9 dos 10 produtos a diferença entre os dois modelos é inferior a 0,7 ponto percentual**, e em 5 deles é inferior a 0,06 ponto. A única separação perceptível ocorre no pão francês, com 2,92 pontos a favor do Holt-Winters — justamente o produto de maior variabilidade do conjunto.

A conclusão que os dados sustentam é, portanto, que **nenhum dos dois modelos domina o outro neste conjunto de dados**. Seria inadequado apresentar o placar de 6 a 4 como evidência de superioridade do Holt-Winters: diferenças dessa ordem de grandeza não são operacionalmente relevantes. A Seção 5.8 demonstra que esse resultado não é fortuito e apresenta o mecanismo que o explica.

Observa-se, em contrapartida, dispersão considerável do erro entre produtos: o MAPE varia de 8,89% a 84,17% entre os vinte pares produto-modelo avaliados. Essa variação acompanha de perto a coluna de variabilidade da Tabela 5.1 — os produtos de demanda mais errática são os de maior erro —, o que confirma a leitura proposta na Seção 5.4: o limite do desempenho é imposto pela parcela aleatória do dado.

O sistema trata explicitamente essa situação. Quando o MAPE do modelo selecionado ultrapassa 50%, o motor preenche um campo de aviso na resposta, e a interface sinaliza a previsão como de confiança reduzida. Trata-se de decisão de projeto deliberada: em vez de apresentar todas as previsões com a mesma autoridade aparente, o sistema comunica ao usuário o grau de confiança associado a cada uma.

5.5.2 Ajuste fora da amostra

As figuras a seguir confrontam a série efetivamente observada na janela de teste com as previsões dos dois modelos, produzidas sem qualquer acesso a esses dias.




Figura 5.3 — Previsto versus real para o Arroz 5kg. As curvas dos dois modelos acompanham o padrão semanal e são visualmente indistinguíveis entre si.




Figura 5.4 — Previsto versus real para a Banana Prata kg. Os modelos reproduzem o ciclo semanal, mas não a amplitude das oscilações diárias.

A leitura da Figura 5.4 merece cuidado para não ser tomada como deficiência do método. Os modelos capturam corretamente o nível e o ciclo semanal do produto; o que não reproduzem são as oscilações diárias, que correspondem ao termo de ruído da série. Um modelo que acompanhasse essas oscilações estaria, na prática, ajustando-se ao ruído — comportamento indesejado que se manifestaria como degradação do desempenho fora da amostra.

5.5.3 Comportamento do erro ao longo do horizonte




Figura 5.5 — Erro absoluto por dia de horizonte, Arroz 5kg.




Figura 5.6 — Erro absoluto por dia de horizonte, Banana Prata kg.

A análise do erro em função do horizonte de previsão tem implicação direta sobre o desenho do sistema. Na formulação do Holt-Winters, a previsão para h dias à frente é dada por $\hat{y}(t+h) = L(t) + h \cdot b(t) + s(\text{dia da semana})$, de modo que qualquer imprecisão na estimativa da tendência $b(t)$ é multiplicada pelo horizonte e se acumula progressivamente. Esse comportamento fundamenta a decisão de limitar a previsão a 30 dias, horizonte alinhado ao ciclo mensal de recálculo adotado pela plataforma.

5.6 Diagnóstico de resíduos

A comparação de métricas informa *quanto* o modelo erra, mas não se ele deixou de aproveitar informação disponível. Esse segundo aspecto é avaliado pela análise dos resíduos, definidos como a diferença entre o valor observado e o previsto. O critério é conhecido: um modelo adequado produz resíduos centrados em zero, sem padrão temporal discernível e sem autocorrelação significativa — em outras palavras, aproximadamente ruído branco. A presença de estrutura nos resíduos indicaria sinal não capturado, e portanto espaço para melhoria do modelo.

Convém enunciar, antes de examinar os gráficos, qual observação refutaria a conclusão pretendida: **um pico significativo na função de autocorrelação no atraso de sete dias** indicaria que a sazonalidade semanal não foi integralmente absorvida pelo modelo, permanecendo no resíduo.




Figura 5.7 — Diagnóstico de resíduos do Arroz 5kg: histograma, evolução temporal e função de autocorrelação.




Figura 5.8 — Diagnóstico de resíduos da Banana Prata kg.

Em ambos os produtos os histogramas apresentam-se aproximadamente simétricos em torno de zero, a evolução temporal não exhibe padrão sistemático e a função de autocorrelação permanece dentro da banda de confiança — inclusive no atraso de sete dias. Conclui-se que os modelos extraíram a estrutura disponível nas séries e que o erro remanescente corresponde à componente irreduzível do processo gerador. A diferença entre os dois produtos está na dispersão dos resíduos, não na presença de padrão, o que é consistente com a caracterização da Seção 5.3.

5.7 Robustez: avaliação em janelas móveis

Uma única divisão entre treino e teste pode, por acaso, favorecer ou prejudicar o modelo avaliado. Para verificar se os resultados da Seção 5.5 são estáveis, aplicou-se avaliação em janelas móveis com origem expansível (*rolling-origin*): em cada uma das cinco repetições, o conjunto de treino cresce e a previsão incide sobre o bloco subsequente de quatorze dias.

Origem da janela	MAPE HW (%)	RMSE HW	MAPE Prophet (%)	RMSE Prophet
2024-10-22	11,84	1,82	11,85	1,80
2024-11-05	12,42	2,82	12,48	2,83
2024-11-19	11,35	1,50	11,34	1,50
2024-12-03	15,65	2,36	15,52	2,36
2024-12-17	10,50	2,11	10,42	2,10

Tabela 5.4 — Avaliação em janelas móveis: Arroz 5kg (id 1).

Origem da janela	MAPE HW (%)	RMSE HW	MAPE Prophet (%)	RMSE Prophet
2024-10-22	34,13	6,30	34,30	6,37
2024-11-05	50,95	7,90	50,77	7,87
2024-11-19	188,42	11,64	185,02	11,60
2024-12-03	31,91	6,59	31,82	6,62
2024-12-17	30,23	7,68	30,21	7,67

Tabela 5.5 — Avaliação em janelas móveis: Banana Prata kg (id 5).




Figura 5.9 — Evolução do MAPE por janela, Arroz 5kg.




Figura 5.10 — Evolução do MAPE por janela, Banana Prata kg.

No arroz, o MAPE permanece entre 10,50% e 15,65% ao longo das cinco repetições — faixa estreita, que indica desempenho consistente e confirma a representatividade da métrica principal relatada na Tabela 5.2.

A banana prata apresenta comportamento distinto: quatro janelas situam-se entre 30,23% e 50,95%, e uma quinta atinge 188,42%. Esse valor discrepante não é omitido porque sua análise é informativa.

Análise da janela discrepante

O RMSE da janela em questão é 11,64, valor apenas moderadamente superior ao das demais repetições — o que descarta uma falha severa de previsão naquele período. A discrepância decorre do comportamento aritmético do MAPE: por dividir o desvio pelo valor observado, a métrica assume valores muito elevados quando coincidem, na janela avaliada, dias de venda reduzida. Confirma-se assim a advertência da Seção 5.2.3 quanto à fragilidade do MAPE em séries de baixo volume, e justifica-se a decisão de reportar as três métricas conjuntamente, em vez de apoiar a análise em uma única.

5.8 Análise dos parâmetros ajustados

A proximidade entre os desempenhos dos dois modelos, verificada na Seção 5.5, admite explicação a partir dos parâmetros que o processo de otimização encontrou. Convém recordar que os parâmetros de suavização do Holt-Winters — α para o nível, β para a tendência e γ para a sazonalidade — não são fixados pelo implementador: são estimados por otimização numérica, de modo a minimizar a soma dos erros quadráticos sobre o conjunto de treino. Seus valores, portanto, constituem informação sobre o dado, e não sobre a configuração do sistema.

id	Produto	α (nível)	β (tendência)	γ (sazonal)
1	Arroz 5kg	0,00000	0,00000	0,00000
2	Feijão Carioca 1kg	0,00000	0,00000	0,00000
3	Leite Integral 1L	0,00004	0,00004	0,00009
4	Pão Francês	0,00202	0,00090	0,00036
5	Banana Prata kg	0,00001	0,00000	0,00009
6	Sal Refinado 1kg	0,00000	0,00000	0,00000
7	Açúcar Cristal 1kg	0,00000	0,00000	0,00000
8	Óleo de Soja 900ml	0,00000	0,00000	0,00000
9	Frango Inteiro kg	0,00000	0,00000	0,00000
10	Refrigerante 2L	0,00000	0,00000	0,00000

Tabela 5.6 — Parâmetros de suavização estimados pelo otimizador, por produto.

O resultado é uniforme: **em todos os dez produtos os três parâmetros convergiram para valores nulos ou desprezíveis**. Em 7 deles a convergência foi exatamente para zero; nos 3 restantes, nenhum parâmetro supera 3×10^{-3} . O argumento desenvolve-se em três etapas.

Primeira etapa: o que a nulidade dos parâmetros significa

Retome-se a equação de atualização do nível, $L(t) = \alpha \cdot (y(t) - s(t-7)) + (1-\alpha) \cdot (L(t-1) + b(t-1))$. Com α igual a zero, o termo associado à nova observação desaparece integralmente, restando $L(t) = L(t-1) + b(t-1)$. O nível deixa de reagir ao que é observado e passa a seguir uma progressão determinística. O mesmo ocorre com a tendência e com a componente sazonal quando β e γ se anulam. O modelo, nessas condições, degenera para:

$$\hat{y}(t) = L_0 + t \cdot b_0 + s(\text{dia da semana})$$

Isto é: uma reta somada a um perfil semanal fixo, ambos estimados uma única vez sobre o histórico e jamais atualizados. O Holt-Winters deixa de operar como filtro adaptativo e passa a comportar-se como um modelo de regressão global sobre o tempo.

Segunda etapa: a convergência das duas formas funcionais

Considere-se agora o que o Prophet ajusta neste mesmo cenário. Sua componente de tendência é linear por partes, com pontos de quebra submetidos a regularização; na ausência de quebras reais na série, a regularização anula os incrementos e resta uma tendência linear simples. Sua componente sazonal é uma série de Fourier de período semanal, estimada globalmente e fixa ao longo de toda a série. O modelo resultante é, portanto, uma reta somada a um perfil semanal fixo — **a mesma família de funções à qual o Holt-Winters degenerou**.

Sob essa perspectiva, a proximidade dos resultados deixa de ser surpreendente. Dois procedimentos de otimização distintos, aplicados à mesma família funcional e ao mesmo conjunto de dados, produzem estimativas quase idênticas. As diferenças de MAPE observadas na Tabela 5.3, situadas na terceira casa decimal para a maioria dos produtos, refletem apenas variações numéricas entre os dois otimizadores.

Terceira etapa: por que o otimizador chegou a esses valores

O processo gerador descrito na Seção 5.2.1 produz tendência rigorosamente linear e perfil semanal constante ao longo de todo o período. Nesse regime, adaptar-se à observação recente é estritamente prejudicial ao desempenho: como a estrutura verdadeira nunca se altera, qualquer reação a uma observação individual constitui reação a ruído. O otimizador identificou essa propriedade e suprimiu a adaptação, atribuindo peso nulo às atualizações.

Dupla conclusão

O resultado valida a implementação do motor. Submetido a dados cuja estrutura é conhecida por construção, o procedimento de estimação recuperou não apenas essa estrutura — nível, tendência e perfil semanal — como também a propriedade de que ela é estacionária. É o comportamento esperado de um estimador corretamente implementado, e constitui a evidência mais forte produzida por esta validação de instrumentação.

O resultado delimita o alcance da conclusão comparativa. A equivalência entre os modelos é propriedade deste conjunto de dados, e não uma afirmação geral sobre Holt-Winters e Prophet. Decorre daí uma previsão verificável: em séries reais, sujeitas a mudanças de patamar, alterações de mix e sazonalidade que evolui, espera-se estimativa de α estritamente positiva e separação de desempenho consideravelmente maior entre os dois métodos.

Essa previsão fundamenta uma decisão de arquitetura da plataforma. Se a equivalência observada fosse tomada como resultado geral, seria razoável descartar um dos modelos e simplificar o sistema. Como a equivalência é condicionada à estacionariedade da série — condição que dados reais não satisfazem —, **justifica-se manter os dois modelos com seleção automática por produto**, mecanismo que se torna operante precisamente nos casos em que os métodos divergem.

5.9 Da previsão à decisão de reposição

A previsão de demanda constitui insumo, não produto final. O que a plataforma entrega ao gestor é uma decisão: em que nível de estoque emitir novo pedido e que reserva manter para absorver incerteza. Essa conversão emprega a formulação de Ballou (2006).

O nível de serviço — probabilidade almejada de não haver ruptura durante o prazo de entrega, fixada em 95% por padrão — é convertido no multiplicador Z da distribuição normal padrão. O cálculo é dinâmico, o que merece registro: em implementações que fixam Z em 1,645, o parâmetro de nível de serviço torna-se inoperante, pois alterá-lo não produz efeito algum sobre o resultado. Na implementação adotada, elevar o nível de 95% para 99% altera Z para 2,326 e eleva proporcionalmente a reserva calculada.

```
Z = norm.ppf(nível de serviço)
ES = Z · √( LT · σ²_demanda + demanda² · σ²_leadtime )
PR = demanda_média_diária · LT + ES
```

A fórmula do estoque de segurança incorpora **duas fontes de incerteza simultaneamente**: a variabilidade da demanda, no primeiro termo do radicando, e a variabilidade do prazo de entrega, no segundo. A formulação simplificada frequentemente encontrada na literatura aplicada, $Z \cdot \sigma \cdot \sqrt{LT}$, desconsidera a segunda parcela. Em mercados de bairro, nos quais o atraso do fornecedor constitui ocorrência rotineira, essa omissão subdimensiona sistematicamente a reserva.

A Tabela 5.7 apresenta o resultado do cálculo para os dois produtos analisados, com prazo de entrega de três dias, variabilidade de prazo igual a 1,0 e nível de serviço de 95%.

Etapas do cálculo	Arroz 5kg (id 1)	Banana Prata kg (id 5)
Modelo selecionado	prophet	prophet
Demanda média prevista (un/dia)	13,092	15,267
σ da demanda histórica	5,459	10,573
Z para nível de 95%	1,6449	1,6449
Estoque de segurança	26,56	39,22
Ponto de reposição	65,84	85,02
Estoque atual	15	200
Dias até ruptura	1,15	13,10

Tabela 5.7 — Parâmetros de reposição calculados pelo motor.




Figura 5.11 — Projeção de estoque do Arroz 5kg, com marcação do ponto de reposição e do estoque de segurança.




Figura 5.12 — Projeção de estoque da Banana Prata kg.

A interpretação operacional é imediata. O arroz possui 15 unidades em estoque contra ponto de reposição de 65,84 — situação em que o pedido já deveria ter sido emitido, com ruptura estimada em 1,15 dia. A banana prata, com 200 unidades contra ponto de reposição de 85,02, encontra-se em situação folgada, com cobertura estimada de 13,10 dias.

Registre-se que o estoque de segurança da banana prata supera o do arroz — 39,22 contra 26,56 unidades — ainda que as demandas médias sejam próximas. A diferença decorre do desvio padrão da demanda, presente no radicando da fórmula: produtos mais erráticos exigem reserva maior para o mesmo nível de serviço. **Verifica-se assim que o sistema compensa automaticamente a menor previsibilidade de um item com maior proteção contra ruptura**, o que atenua, no plano da decisão, o efeito do MAPE elevado discutido na Seção 5.5.

5.10 Limitações e ameaças à validade

As limitações a seguir foram identificadas por inspeção do código e do delineamento experimental, e são declaradas para delimitar com precisão o alcance das conclusões deste capítulo.

5.10.1 *Natureza sintética dos dados*

A validação demonstra a correção da implementação e a adequação da metodologia, não o desempenho preditivo em operação real. É a limitação mais relevante e condiciona todas as demais conclusões.

5.10.2 *Geração multiplicativa e ajuste aditivo*

O processo gerador compõe os fatores por multiplicação, ao passo que os modelos e a decomposição empregam formulação aditiva. Com crescimento de apenas 20% no período, a discrepância é pequena, mas constitui incoerência metodológica que convém registrar.

5.10.3 *Ausência de comparação com métodos ingênuos*

Não foram avaliados estimadores de referência, como a repetição do valor observado sete dias antes ou a média por dia da semana. Sua inclusão permitiria quantificar o ganho absoluto dos modelos, e não apenas a diferença entre eles. Dado o resultado da Seção 5.8, há hipótese plausível de que um estimador de média por dia da semana com tendência apresente desempenho próximo ao dos dois modelos neste conjunto de dados.

5.10.4 *Regressor de promoções não ativado*

O campo previsto no contrato de entrada não é repassado ao Prophet. No conjunto sintético a omissão é inócua, pois a variável é constante e não possui variância; sua avaliação exige dados reais contendo promoções.

5.10.5 *Tratamento de feriados não ativado no Prophet*

O modelo dispõe de mecanismo nativo para efeitos de calendário, sem equivalente no Holt-Winters, que não foi habilitado. Como o conjunto de dados contém doze feriados com elevada probabilidade de fechamento, essa é a alteração de maior potencial para diferenciar os dois métodos.

5.10.6 *Desvio padrão calculado sobre a série integral*

O σ empregado na fórmula do estoque de segurança inclui os dias de fechamento, o que eleva a dispersão estimada e, por consequência, a reserva calculada. A escolha é conservadora — erra no sentido de excesso de estoque —, mas não é neutra.

5.10.7 *Fragilidade do MAPE em séries de baixo volume*

Documentada nas Seções 5.2.3 e 5.7. Métricas alternativas, como o SMAPE ou o MASE, mitigariam o problema e poderiam ser adotadas como critério de desempate.

5.10.8 *Truncamento assimétrico das previsões*

A previsão entregue é truncada em zero, enquanto as métricas são calculadas sobre a previsão bruta. Em produtos de tendência decrescente, o modelo aditivo poderia ser penalizado por valores negativos que jamais seriam exibidos. No conjunto avaliado, de tendência crescente, o efeito é nulo.

5.10.9 *Sensibilidade da reprodutibilidade à ordem do catálogo*

O gerador consome um único fluxo de números pseudoaleatórios de forma sequencial. A inserção ou reordenação de produtos desloca as séries subsequentes, de modo que novos itens devem ser acrescentados ao final da lista para preservar a reprodutibilidade.

5.10.10 Impossibilidade de estimar sazonalidade anual

Um período de 365 dias não comporta a estimação de ciclo anual, que exigiria ao menos dois ciclos completos. A componente anual do Prophet foi desabilitada por essa razão.

5.11 Síntese do capítulo

Os experimentos descritos permitem sustentar as seguintes afirmações:

1. As séries de demanda contêm sinal previsível — tendência e sazonalidade semanal separáveis do termo aleatório —, o que justifica o emprego de modelos de série temporal (Seção 5.4).
2. Ambos os modelos generalizam para dados não observados, com erro que varia de 8,89% a 84,17% conforme a variabilidade intrínseca de cada produto (Seção 5.5).
3. O ajuste é adequado: os resíduos não retêm estrutura discernível (Seção 5.6) e o desempenho mantém-se estável em janelas de avaliação independentes (Seção 5.7).
4. A equivalência de desempenho entre Holt-Winters e Prophet possui explicação mecânica verificável — a convergência dos parâmetros de suavização a zero, que reduz ambos à mesma família funcional — e está condicionada à estacionariedade da série avaliada (Seção 5.8).
5. A previsão converte-se em parâmetros de reposição coerentes, e o dimensionamento da reserva compensa automaticamente a menor previsibilidade dos produtos mais erráticos (Seção 5.9).

A validação externa, sobre o histórico de vendas de um estabelecimento real, deverá verificar em que medida essas conclusões se sustentam fora do regime estacionário. Espera-se, em particular, que os parâmetros de suavização assumam valores estritamente positivos e que a diferença de desempenho entre os modelos se amplie — hipótese que, uma vez confirmada, converteria o mecanismo de seleção automática por produto de precaução arquitetural em componente operante do sistema.